

Tuner-2

Автономная Мультиагентная Система для Fine-Tuning LLM

- Автоматизация процесса
- Оптимизация под слабое железо
- Фокус на данных

<> [GitHub](#)  [GitLab](#)

v2.0

ML? It's simple.

 CLI Tool

 Multi-Agent

Проблемы при Fine-Tuning LLM



Ручная настройка окружения

Установка и настройка зависимостей занимает часы



CUDA Out Of Memory

Ошибки нехватки видеопамяти прерывают обучение



Сложное управление памятью

Настройка `batch_size`, `gradient_accumulation` требует опыта



Конфликты библиотек

Разрешение зависимостей между пакетами PyTorch



Валидация данных

Очистка, форматирование и подготовка датасетов



Мониторинг обучения

Отслеживание процесса в реальном времени

Tuner-2: Автоматический старт



Автодетекция

Hardware Detected

Система автоматически определяет
ваше оборудование и готова к работе

Linux/Windows/macOS

GPU от 4 ГБ VRAM

Поддержка Apple Silicon

```
yernur@Nitro:~$ tuner
```

TUNER

v2.0 - ML? It's simple.

Hardware Detected

Компонент	Характеристики
Операционная система	Linux (6.17.0-19-generic)
Оперативная память (RAM)	14.93 GB
GPU (NVIDIA)	NVIDIA GeForce RTX 2050
VRAM	4.0 GB
Движок обучения	UNSL0TH (Ultra Fast)

Добро пожаловать в будущее обучения LLM!

1. Train Model (Добучить модель)
2. Chat (Протестировать веса)
3. Dataset Studio (Подготовить данные)
4. Settings (Настройки)
5. Exit (Выход)

Что будем делать? [1/2/3/4/5] (1):

Архитектура: 4 Специализированных агента

1

Commander

Orchestrator Agent

Ядро системы • Маршрутизация
пайплайна • Управление состоянием

2

Hardware Expert

Profiler Agent

Профилирование железа •
Оптимизация `batch_size`,
`gradient_accumulation`

3

Data Scientist

Data Pipeline Agent

Работа с датасетами • Очистка •
Форматирование • Валидация

4

Stability Agent

DevOps/QA Agent

Мониторинг `train_loop` • Перехват
предупреждений • Горячие фиксы

Ключевые особенности



Self-Healing Code

- Интеллектуальное разрешение зависимостей
- Автоматический анализ traceback
- Патчинг библиотек "на лету"



Low-VRAM Optimization

- Запуск на видеокартах от 4 ГБ
- Поддержка RTX 2050 и слабее
- Поддержка Apple Silicon



Интеграция с Unsloth

- Ускорение процесса обучения
- Снижение потребления памяти
- Улучшенная производительность

Выбор модели



Интерактивное меню

Model Selection

Простой интерфейс для выбора и запуска обучения


1 Выберите модель

Qwen 2.5, Llama 3.2 и другие

Поддержка популярных моделей

Автоматическая загрузка

Быстрый запуск обучения



Процесс обучения

▶ Стабильный процесс Real-time Training

Стабильный процесс в реальном времени с автоматическим мониторингом

Прогресс


58–68%

Шаги

35–41 / 60

Скорость

1.70–1.75s/it



Преимущества для разработчика



Экономия времени

Автоматизация рутинных задач



Простота

Нет необходимости разбираться в деталях CUDA



Доступность

Fine-tuning на любом железе от 4 ГБ VRAM



Стабильность

Защищенный процесс без прерываний

<> Технологический стек

Python 3.10+

PyTorch

Transformers

LoRA

Unsloth



Результат

- Фокус только на данных
- Фокус только на моделях
- Никакой рутинной настройки окружения

Tuner-2 делает fine-tuning LLM простым и доступным для каждого